

DATABRICKS CERTIFIED ASSOCIATE DEVELOPER

BLOQUE 1: Fundamentos de Big Data & Apache Spark

Capítulo 1: Ecosistema Moderno de Datos & el Rol del Data Engineer

 Preparación Oficial de Certificación para Apache Spark 3.x

Capítulo 2: Paradigmas de Arquitectura de Datos



Data Lakehouse

Combina la flexibilidad y bajo costo de un **Data Lake** con la estructura, soporte de transacciones ACID y gobernanza de un **Data Warehouse**.

Clave Databricks: Habilitado por el formato open-source *Delta Lake*.



ETL vs. ELT

ETL: Transforma datos antes de cargarlos (Legacy).

ELT: Carga datos raw en la nube y aprovecha el motor distribuido para transformar in-situ.

Databricks Tip: Promueve ELT usando Delta Live Tables y Spark SQL.



Batch vs. Streaming

Batch: Procesamiento por lotes periódicos (ej: nocturnos).

Streaming / NRT: Procesamiento continuo micro-batch evento por evento con Structured Streaming.

Examen: Spark usa la misma API (DataFrame) para Batch y Streaming.

Capítulo 3: Definición de Big Data & Las 5 V's

5 V's

Desafíos del Gran Volumen de Datos



Volumen: Escala masiva de terabytes a petabytes que no caben en memoria o disco único.



Velocidad: Ritmo acelerado de generación y requerimiento de ingestión (IoT, Clickstreams).



Variedad: Estructurados (SQL), Semi-estructurados (JSON, Parquet) y No estructurados (Imágenes, Texto).



Veracidad: Calidad, inconsistencias y limpieza de datos en el origen.



Valor: Capacidad de convertir datos crudos en métricas de negocio accionables.

Capítulo 4: Computación Distribuida


Anatomía de un Cluster de Spark

Driver Node: El cerebro del cluster. Mantiene la sesión (SparkSession), coordina la ejecución, convierte el código en un Plan de Ejecución (DAG) y distribuye las tareas.

Worker Nodes & Executors: Los procesos que ejecutan las tareas individuales en paralelo y almacenan datos en memoria RAM o disco local.

Particiones: División lógica de un conjunto de datos masivo. Un executor procesa 1 partición por core a la vez.

Error Común: El Driver NO procesa datos masivos; si ejecutas `.collect()` en un dataset gigante, causarás un `OutOfMemoryError` en el Driver.



Capítulo 5: Evolución: De Hadoop a Apache Spark

Hadoop MapReduce (Legacy)

- Escribe y lee resultados intermedios en disco duro (HDFS) en cada etapa de Map y Reduce.
- Operaciones lentas limitadas por la latencia de I/O de disco.
- Código complejo, rígido y difícil de mantener.
- Ineficiente para algoritmos iterativos (Machine Learning e Inteligencia Artificial).

Apache Spark (En Memoria)

- Procesamiento en memoria RAM (hasta 100x más rápido que MapReduce).
- Evaluación perezosa (Lazy Evaluation) para optimizar el DAG antes de ejecutar.
- APIs unificadas en Python (PySpark), Scala, SQL, R y Java.
- ¿Cuándo **NO** usar Spark? Datos pequeños (< 10GB) que entran en una sola máquina con Pandas.

Capítulo 6: Ecosistema & Módulos de Apache Spark



Spark Core

Motor de ejecución base. Gestiona memoria, evaluación perezosa, planificación de tareas y la abstracción fundamental **RDD** (Resilient Distributed Datasets).



Spark SQL & DataFrames

Módulo de alto nivel optimizado con el motor **Catalyst Optimizer** y el motor de ejecución en código máquina **Tungsten**. Core de la certificación.




Structured Streaming & MLlib

Streaming tolerante a fallos basado en el motor Spark SQL y librería distribuida para algoritmos de Machine Learning a gran escala.

Capítulo 7: Plataforma Databricks & Lakehouse

-  **Workspace:** Entorno colaborativo basado en Notebooks con soporte para código políglota (Python, SQL, Scala, Markdown).
-  **Clusters & Jobs:** Gestión automatizada de infraestructura de cómputo (All-Purpose para desarrollo, Job Clusters para producción).
-  **Unity Catalog:** Solución unificada de gobernanza de datos e IA para control de acceso, linaje y auditoría.

Delta Lake: Capa de almacenamiento open-source que aporta transacciones ACID, Travel Time (versionado) y alto rendimiento Parquet.



Capítulo 8: Casos de Uso Empresariales Reales

Empresa	Desafío de Datos	Solución con Spark / Databricks
Netflix	Procesar miles de millones de eventos diarios de streaming de video para recomendaciones.	Pipeline de Structured Streaming continuo para alimentar modelos de personalización en tiempo real.
Uber	Calcular tarifas dinámicas y estimaciones de Llegada (ETA) con datos de GPS en vivo.	Procesamiento geoespacial distribuido en Spark para procesamiento de eventos en milisegundos.
Airbnb	Analizar petabytes de búsquedas, precios no estructurados y fotos de propiedades.	Data Lakehouse unificado con Delta Lake para analítica de precios e Inteligencia de Negocio.

Capítulo 9: Laboratorio Práctico: Despliegue Inicial

- 1 Paso 1: Configurar Workspace (Community o Cloud):** Crear cuenta en Databricks Community Edition o desplegar el recurso desde AWS / Azure / GCP.
- 2 Paso 2: Crear un Compute Cluster:** Configurar runtime Databricks Runtime (DBR 13.3 LTS or superior), seleccionar tipo de nodo Driver y Workers (Auto-scaling).
- 3 Paso 3: Crear el Primer Notebook:** Seleccionar lenguaje primario (Python/PySpark), asociar el notebook al cluster activo.
- 4 Paso 4: Verificación de SparkSession:** Ejecutar `spark.version` y realizar una transformación simple `spark.range(10).count()` para comprobar la ejecución distribuida.

Capítulo 10: Mapa Conceptual de Aprendizaje



Capítulo 11: Preguntas Tipo Examen Databricks

Pregunta 1: Arquitectura de Cluster

¿Cuál de los siguientes componentes es responsable de convertir el código de la aplicación en un DAG (Graph Acyclic Directed) y programar las tareas en los executors?

- A) Worker Node
- B) SparkSession
- C) Driver Node (Correcta)**
- D) Cluster Manager

Pregunta 2: Evaluación Perezosa

¿Cuál de las siguientes operaciones desencadenará la ejecución inmediata de un Job en el cluster de Spark?

- A) `df.select("col1")`
- B) `df.filter(df.id > 10)`
- C) `df.count()` (Correcta - Es una Acción)**
- D) `df.withColumnRenamed(...)`

Capítulo 12: Bibliografía & Recursos Oficiales

-  **Libros Recomendados:** *"Learning Spark (2nd Edition)"* — Jules S. Damji et al. (O'Reilly) & *"Spark: The Definitive Guide"* — Matei Zaharia & Bill Chambers.
-  **Documentación Oficial:** [Apache Spark Documentation](#), [Databricks Docs](#) y [Delta Lake Docs](#).
-  **Whitepapers Académicos:** *"Resilient Distributed Datasets (RDDs)"* (Zaharia et al., UC Berkeley) y *"Lakehouse: A New Generation of Open Platforms"*.
-  **Cursos & Certificación:** Databricks Academy — *Databricks Certified Associate Developer for Apache Spark Exam Guide*.

Image Sources



https://www.networkworld.com/wp-content/uploads/2025/05/3992283-0-42914200-1747839140-shutterstock_2200880613-100963279-orig.jpg?quality=50&strip=all&w=1024

Source: www.networkworld.com



<https://uptimerobot.com/knowledge-hub/wp-content/uploads/2025/02/cloud-infrastructure-components.png>

Source: uptimerobot.com